

Uma Análise da Produção Científica Brasileira em Conferências de Manutenção e Evolução de Software

Klérison Paixão¹, Marcelo de A. Maia¹, Marco Tulio Valente²

¹ Faculdade de Computação, Universidade Federal de Uberlândia

² Departamento de Ciência da Computação, Universidade Federal de Minas Gerais

{klerisson, marcelo.maia}@ufu.br, mtov@dcc.ufmg.br

Abstract. *The Brazilian scientific community of Software Maintenance and Evolution presents effective participation in several international scientific conferences of the highest quality standard. This article aims to analyze the scientific papers published in selected conferences over the last 5 years. The information gathered allows us to reach the following conclusions: (i) Brazilian researchers participate in almost all major conferences in the area; (ii) the leading institutions on publication ranking in this area are: UFMG, UFPE, and UFRN; (iii) Six are the central themes addressed in the publications.*

Resumo. *A comunidade científica brasileira de Manutenção e Evolução de Software apresenta efetiva participação em várias conferências científicas internacionais do mais alto padrão de qualidade. Este artigo tem o objetivo de analisar os artigos científicos publicados em conferências selecionadas nos últimos 5 anos. As informações levantadas permitem chegar às seguintes conclusões: (i) a produção brasileira apresenta participação em quase todas as principais conferências da área; (ii) as instituições que lideram o ranking de publicações nesta área são: UFMG, UFPE e UFRN; (iii) Seis foram os temas centrais tratados nas publicações.*

1. Introdução

Já com mais de três décadas de existência a comunidade científica brasileira de Engenharia de Software contabiliza significativos avanços na produção de trabalhos de alta qualidade [Neto et al. 2013]. Em especial, a comunidade de Manutenção e Evolução de Software demonstra efetiva participação em várias conferências científicas internacionais do mais alto padrão de qualidade. Contudo, não há na literatura um mapa que retrate os avanços dessa comunidade.

Análise bibliométrica é uma técnica comum para analisar publicações científicas. Um dos objetivos dessa análise é extrair introspecções sobre uma área e/ou comunidade de pesquisa. Por exemplo, tal análise ajuda a entender aspectos sobre a disseminação do conhecimento criado [Vasilescu et al. 2014], produtividade de autores e grupos [Garousi and Varma 2010], como está a evolução da área [Hoonlor et al. 2013] e tendências no interesse dos pesquisadores [Mathew et al. 2018].

Assim, neste artigo apresenta-se um estudo bibliométrico e de mineração de publicações científicas para retratar a produção brasileira em Manutenção e Evolução de Software. Este primeiro estudo se restringe a analisar publicações de conferências que, tipicamente, são o principal veículo de disseminação de artigos em Ciência da Computação [Meyer et al. 2009]. Além disso, são analisados os últimos 5 anos em cada conferência para mapear os avanços mais recentes. Especificamente, são propostas três questões de pesquisa:

QP#1 Qual a produção brasileira nas conferências selecionadas?

QP#2 Quais são os grupos brasileiros que publicaram nas conferências selecionadas?

QP#3 Quais os principais temas pesquisados?

Para responder a essas questões, foram analisados 96 artigos científicos publicados em conferências internacionais selecionadas. Os resultados mostram que: (i) a produção brasileira apresenta participação em quase todas as principais conferências da área; (ii) as instituições que lideram o ranking de publicações nesta área são: UFMG, UFPE e UFRN. Em parceria com outras instituições, pesquisadores dessas três universidades são responsáveis por mais de 40% da produção científica; (iii) Seis foram os temas mais frequentes tratados nas publicações brasileiras.

2. Método de Pesquisa

2.1. Seleção de Conferências

Várias conferências sobre Engenharia de Software são organizadas todos anos, sendo que em grande parte Manutenção de Software é um tema recorrente nessas conferências. No entanto, neste estudo o foco está em conferências com níveis de seletividade elevados para publicação de artigos.

Sendo assim, optou-se por analisar as conferências listadas no sistema CSINDEXBR [Valente and Paixão 2018]. Tal sistema indexa artigos completos de autores brasileiros publicados na trilha principal de conferências selecionadas em Ciência da Computação. Para uma conferência se integrar a base do CSINDEXBR, basicamente, três critérios são exigidos: (i) número de submissão de artigos maior que 100; (ii) taxa de aceitação menor que 30%; (iii) índice $h5$ maior que 20¹. Embora haja exceções a estes critérios no CSINDEXBR, neste estudo foram consideradas todas as conferências listadas na área de Engenharia de Software, totalizando 16 conferências. Na Figura 1 são apresentadas as quantidades de artigos aceitos e rejeitados por conferência em 2017.




Figura 1. Estatísticas gerais das conferências selecionadas no ano de 2017.

2.2. Seleção de Artigos

O CSINDEXBR provê a lista de artigos publicados em cada uma das conferências. A seguir são descritos os passos para selecionar os artigos relacionados a Manutenção de Software:

¹ $h5$ é o maior número h tal que h artigos publicados nos últimos 5 anos tenha pelo menos h citações.

1. Os artigos publicados de 2013 a 2017 foram todos selecionados. Os artigos de 2018 foram descartados, pois apenas uma das 16 conferências teve seus artigos indexados ainda.
2. Leitura de títulos e resumos foram feitas pelos autores deste trabalho separadamente e cada qual julgou a aderência dos artigos à sub-área de Manutenção.
3. Os respectivos julgamentos foram debatidos conjuntamente entre os autores para se chegar a um consenso.
4. Nos casos em que não houve consenso prevaleceu o julgamento maioritário.

Por fim, 62 artigos dos 96 artigos publicados pela comunidade brasileira entre 2013-2017 nas 16 conferências foram selecionados².

2.3. Análise dos Artigos

Para responder as questões de pesquisa foi conduzida uma análise exploratória de dados de modo a resumir as características principais das conferências e produção brasileira.

Para identificar os principais comunidades de pesquisa, além de afiliação de cada autor, foram feitas análises de redes de coautoria. Uma rede de coautoria é composta de nós e arestas, onde os nós são os autores dos artigos e as arestas indicam que os autores relacionados publicaram em conjunto. Especificamente, são apresentados três aspectos da rede: (i) grau de conectividade de autores que corresponde ao número de arestas incidentes ou o quanto colabora com os outros autores; (ii) centralidade de intermediação (*betweenness*) que indica a importância de um autor na interligação de outros autores da rede; (iii) identificação de comunidades (subgrafos) dentro da rede de coautoria.

Por fim, análise de tópicos foi utilizada para caracterizar os principais temas dos artigos publicados. A definição do número de tópicos, neste caso seis, foi feita com base na métrica de coerência de tópicos. Conforme a Figura 2, observa-se que até seis tópicos o nível de coerência estava se elevando, mas começa a decair com mais tópicos. De fato, com 10 tópicos o nível de coerência se eleva novamente, no entanto, conforme Figuras 3(a) e 3(b), com 10 tópicos ocorrem maiores interseções entre tópicos o que não é ideal para categorizar os artigos.




Figura 2. Coerência

3. Resultados

QP#1 Qual a produção brasileira nas conferências selecionadas?

Na Figura 4 são apresentados a quantidade total de artigos com autores brasileiros nas conferências selecionadas, bem como a quantidade selecionada para este estudo. Observa-se que as publicações brasileiras estão presentes em quase todas as principais conferências sobre Engenharia de Software. Apenas na conferência ISSTA não houve publicações brasileiras nos últimos 5 anos.

Outro ponto de destaque é a quantidade de artigos aderentes a sub-área de Manutenção e Evolução de Software. Até mesmo conferências predominantemente de outras sub-áreas como ICST (Teste de Software) e ESEM (Engenharia de Software Experimental) publicam trabalhos sobre Manutenção de Software. Por outro lado, nas conferências ICSA, MODELS e RE não encontramos trabalhos sobre manutenção.

²<https://zenodo.org/record/1303392>




Figura 3. Inter-distância entre tópicos.




Figura 4. Distribuição de artigos por conferências publicados entre 2013–2017

QP#2 Quais são os grupos brasileiros que publicaram nas conferências selecionadas?

A Figura 5 apresenta a quantidade percentual de publicações das instituições brasileiras. Observa-se que pouco mais de um terço dos trabalhos sobre Manutenção e Evolução de Software são oriundos ou feitos em parceria com pesquisadores da UFMG e UFPE. Além disso, nota-se que sete instituições concentram dois terços dos trabalhos publicados. A última terça parte tem participação de mais 12 instituições. Embora haja uma concentração em poucas instituições, nota-se que os trabalhos foram feitos em grande parte em colaboração com outras instituições. Por exemplo, dos 17 artigos da UFMG 10 tiveram participação de outras instituições brasileiras (i.e., CEFET/MG, PUC-Minas, PUC-Rio, UFLA, UFMS e UFU). No caso da UFPE, 6 artigos envolveram pesquisadores de outras 4 instituições (i.e., UFAL, UFCG, UNB, UFPA), do total de 16.




Figura 5. Percentual de artigos publicados por instituição.

Para aprofundar no aspecto de colaboração entre pesquisadores a Figura 6 apresenta a rede de coautoria. Perceba que nesta rede autores estrangeiros estão presentes. No total a rede contém 158 pesquisadores e 448 relações entre os pesquisadores. O grau

médio de conectividade é de 5,67, ou seja, na média cada pesquisador publicou trabalhos com outros 5 pesquisadores. No entanto, o maior grupo conectado tem diâmetro igual a 12. A densidade da rede, ou seja, a proporção de arestas diretas existentes em relação a quantidade total de possíveis arestas, é de apenas 3%. As Tabelas 1(a) e 1(b) apresentam o grau de conectividade dos 10 pesquisadores mais conectados e a centralidade de intermediação dos 10 pesquisadores que unem grandes sub-grupos, respectivamente.

Tabela 1. Conectividade e centralidade dos pesquisadores.

(a)		(b)	
Pesquisador	#	Pesquisador	#
Alessandro Garcia (PUC-Rio)	33	Rodrigo Bonifácio (UNB)	0.25
Marco Túlio Valente (UFMG)	27	Rohit Gheyi (UFCG)	0.22
Rohit Gheyi (UFCG)	23	Roberta Coelho (UFRN)	0.21
Márcio Ribeiro (UFAL)	20	Marco Tulio Valente (UFMG)	0.20
Marcelo d' Amorim (UFPE)	18	Alessandro Garcia (PUC-Rio)	0.20
Fernando Castor (UFPE)	14	Paulo Borba (UFPE)	0.19
Eiji Adachi Barbosa (UFRN)	12	Marco Aurélio Gerosa (IME-USP)	0.15
Paulo Borba (UFPE)	12	Márcio Ribeiro (UFAL)	0.13
Baldoino Fonseca (UFAL)	11	Gustavo Pinto (UFPA)	0.13
Leonardo da S. Sousa (PUC-Rio)	11	Leopoldo Teixeira (UFPE)	0.08

Uma forma comum para se extrair comunidades de uma rede é por meio da métrica de modularidade. Neste trabalho, o número de comunidades é dado pelo maior número de partições em um dendrograma gerado pelo algoritmo de *Louvain* [Blondel et al. 2008]. Uma comunidade possui alta conectividade entre os próprios membros da comunidade, mas baixa conectividade fora da comunidade. A Tabela 2 apresenta as comunidades de maior afinidade entre os pesquisadores brasileiros. No total foram encontradas 11 comunidades.

QP#3 Quais os principais temas pesquisados?

Nessa última questão de pesquisa analisa-se os temas publicados pelos pesquisadores brasileiros. A Figura 7 congrega os 6 tópicos com as 10 palavras mais frequentes para cada tópico. Ainda na mesma figura o número de artigos classificados automaticamente é apresentado por tópico. Observa-se dois tópicos com maior número de artigos, Figuras 7(a) e 7(b), nos quais pode-se inferir que são artigos relacionados ao tema Linha de Produtos de Software e Refatoração de Código, respectivamente. Em seguida, tem-se dois tópicos que tratam predominantemente sobre desenvolvedores, mas um com relação a *bugs* e códigos aberto e o outro tópico com relação a transformações e mudança de códigos, Figuras 7(c) e 7(d). Por fim, tem-se os tópicos com menor quantidade de artigos, Figuras 7(e) e 7(f), que tratam de análises de consumo energético e impacto de mudanças.

4. Ameaças à Validade

Validade Externa: Este estudo limitou-se a análise de 92 trabalhos publicados em conferências monitoradas pelo CSINDEXBR. Portanto, os resultados reportados não podem ser generalizados para outras fontes de dados.

Validade Interna: Dentre os aspectos que podem afetar os resultados apresentados, destaca-se o método para seleção dos trabalhos analisados. A fim de minimizar essa ameaça, a seleção foi feita separadamente por cada autor deste trabalho em seguida foi feita uma etapa de discussão sobre cada julgamento conjuntamente.




Figura 6. Rede de coautoria dos pesquisadores brasileiros e estrangeiros.

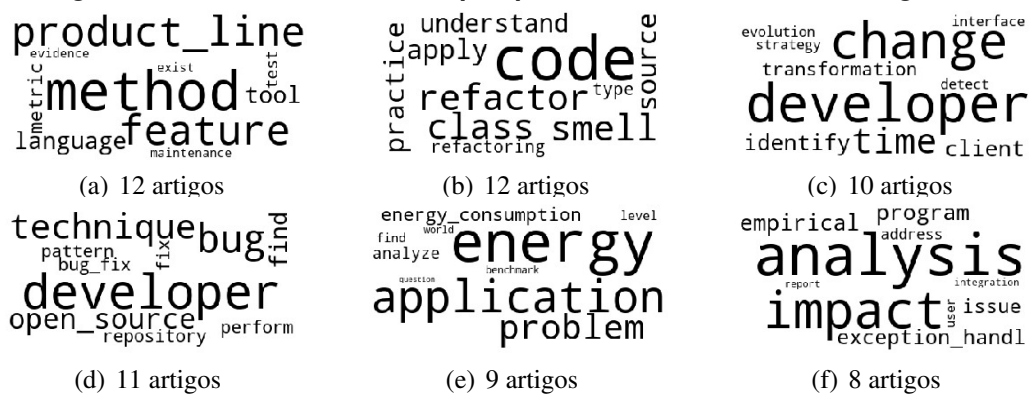


Figura 7. Tópicos e distribuição de artigos.

5. Trabalhos Relacionados

Alguns trabalhos analisam características de conferências onde artigos científicos são publicados. Em Engenharia de Software, Vasilescu et al. analisaram 10 anos de 11 conferências [Vasilescu et al. 2014]. Introduziram métricas que quantificam a representatividade do comitê de programa, prestígio científico, abertura para novos autores entre outros aspectos. Com foco em um dos principais periódicos em Engenharia de Software (i.e.,

Tabela 2. Sub-grupos que possuem alta conectividade entre membros

#	Pesquisadores
1	Adriano C. de Paula, Felipe C. Zanichelli, Otávio Augusto L. Lemos
2	Daniel A. da Costa, Demóstenes Sena, Gustavo A. Oliva, Igor S. Wiese, Igor Steinmacher, José T. da Silva, Lucas Almeida, Marco Aurélio Gerosa, Mauricio F. Aniche, Roberta Coelho, Tayana U. Conte, Uirá Kulesza
3	Alessandro Garcia, Arthur Cassio, Benjamin Jakobus, Bruno B. P. Cafeo, Carlos José P. de Lucena, Danyllo Albuquerque, Eduardo Figueiredo, Eiji A. Barbosa, Eliezio Soares, Frederico Pranto, Gustavo Vale, Israel García, Juliana Araujo, Nélío Cacho, Rafael Souza, Thiago César, Thomas Filipe, Willian Nalepa Oizumi
4	Alexander Chávez, Baldoino Fonseca, Diego Cedrim, Eduardo Monteiro, Flávio Medeiros, Francisco Dalton, Gustavo Mendes, Gustavo Soares, Leonardo da Silva Sousa, Márcio Ribeiro, Rafael Maiani de Mello, Reudismam Rolim, Rodrigo Bonifácio, Rohit Gheyi, Romero Malaquias
5	Aline Brito, André C. Hora, Danilo Silva, Eduardo Campos, Fernando P. Lima, Gleison Brito, Guilherme Avelino, Gustavo Santos, Henrique Rocha, Humberto Marques-Neto, Jailton Coelho, Kecia Aline M. Ferreira, Klérissou Paixão, Laerte Xavier, Leonardo H. Silva, Lucas B. L. de Souza, Luciana L. Silva, Marcelo de A. Maia, Marco Tulio Valente, Miguel Ramos, Mívian M. Ferreira, Paloma Oliveira, Ricardo Terra
6	Alexandre Melo Braga, Evandro de B. Costa, Mario Hozano, Ricardo Dahab
7	Marcelo d'Amorim, Mateus Borges, Paulo Barros, Sabrina Souto
8	Gabriela Sampaio, Guilherme Cavalcanti, Leopoldo Teixeira, Paola R. G. Accioly, Paulo Borba, Vander Alves
9	Anita Sarma, Catarina Costa, Esteban Clua, Jair Figueiredo, Jose Ricardo da Silva Jr., Leonardo Murta
10	Felipe Ebert, Fernando Castor, Francisco Soares-Neto, Gilberto Melfe, Gustavo Pinto, Irineu Moura, João Paulo Fernandes, Luis Gabriel Lima, Paulo Lieuthier, Renato Oliveira, Wellington Oliveira
11	Cristiano Werner Araújo, Daltro José Nunes, Ingrid Nunes, Vanius Zapalowski

Transactions on Software Engineering), Hamadicharef analisou o número de publicações, distribuição de citações e redes de colaboração [Hamadicharef 2011]. Ainda reporta um estudo sobre ocorrência de palavras chaves nos títulos publicados para mostrar tendências naquele periódico. Mathew et al. usou análise de tópicos para sumarizar numerosas quantidades de artigos científicos em Engenharia de Software [Mathew et al. 2018]. Os resultados mostram que análise de tópicos tem potencial para detectar tendências em uma comunidade.

Alguns trabalhos investigaram a produção científica da comunidade brasileira em Ciência da Computação. Costa et al. analisou redes de coautoria de artigos publicados em 30 edições do Simpósio Brasileiro de Banco de Dados [Costa de Lima et al. 2017]. Carianha e Neto exploraram 5 edições do Simpósio Brasileiro de Qualidade de Software e reportaram análises demográficas sobre aquela comunidade, bem como os principais tópicos publicados no evento [Carianha and Neto 2013]. Leite et al. reportam análises quantitativas de 5 edições do Simpósio Brasileiro de Engenharia de Software (SBES) e concluíram que Teste de Software foi a área com maior número de publicações naquela comunidade [Leite et al. 2011]. Mais dois trabalhos investigam publicações do SBES. O primeiro reporta uma análise qualitativa de 126 artigos com o objetivo de identificar

falhas em estudos experimentais [Monteiro et al. 2017]. Por último, 25 edições do SBES foram mapeadas identificando os principais grupos de pesquisa, sub-áreas, distribuição das publicações entre outros aspectos [Neto et al. 2013].

6. Conclusão e Trabalhos Futuros

Este trabalho apresentou um estudo sobre a produção científica brasileira em Manutenção e Evolução de Software em conferências considerados de alto padrão de qualidade. Para isso, foram analisados 96 artigos que foram publicados nestas conferências selecionadas. As informações levantadas nos permitiram chegar às seguintes conclusões: (i) a produção brasileira apresenta participação em quase todas as principais conferências da área; (ii) as instituições que lideram o ranking de publicações nesta área são: UFMG, UFPE e UFRN. Em parceria com outras instituições pesquisadores dessas três universidades são responsáveis por mais 40% da produção científica; (iii) Seis foram os temas centrais tratados nas publicações. Como trabalhos futuros, pretende-se estender este estudo para outras áreas e verificar as semelhanças e diferenças entre comunidades.

Referências

- Blondel, V. D., Guillaume, J.-L., Lambiotte, R., and Lefebvre, E. (2008). Fast unfolding of communities in large networks. *J. Stat. Mech. Theory Exp.*, 2008(10):P10008.
- Carianha, M. S. and Neto, C. R. L. (2013). Uma análise dos últimos 5 anos do Simpósio Brasileiro de Qualidade de Software. In *Proc. SBQS*, pages 153 – 164.
- Costa de Lima, L. H., Penha, G., de Alencar Rocha, L. M., Moro, M. M., Couto da Silva, A. P., Laender, A. H. F., and M. de Oliveira, J. P. (2017). The collaboration network of the Brazilian Symposium on Databases. *J. Braz. Comput. Soc.*, 23(1):10.
- Garousi, V. and Varma, T. (2010). A bibliometric assessment of canadian software engineering scholars and institutions (1996-2006). *Comp. Inform. Sci.*, 3(2):19.
- Hamadicharef, B. (2011). Scientometric study of the iee transactions on software engineering 1980-2010. In *Proc. CACS*, pages 101–106.
- Hoonlor, A., Szymanski, B. K., and Zaki, M. J. (2013). Trends in Computer Science research. *Commun. ACM*, 56(10):74–83.
- Leite, J., Batista, T., and Leite, L. (2011). Software Engineering research in Brazil: An analysis of the last five editions of SBES. In *Proc. SBES*, pages 24–29.
- Mathew, G., Agrawal, A., and Menzies, T. (2018). Trends in topics at SE conferences (1993-2013). *arXiv*, abs/1608.08100.
- Meyer, B., Choppy, C., Staunstrup, J., and van Leeuwen, J. (2009). Viewpoint: Research evaluation for computer science. *Commun. ACM*, 52(4):31–34.
- Monteiro, D., Gadelha, R., Alencar, T., Neves, B., Yeltsin, I., Gomes, T., and Cortés, M. (2017). An analysis of the empirical Software Engineering over the last 10 editions of Brazilian Software Engineering Symposium. In *Proc. SBES*, pages 44–53.
- Neto, P. A. d. M. S., Gomes, J. S., Almeida, E. S. d., Leite, J. C., Batista, T. V., and Leite, L. (2013). 25 years of Software Engineering in Brazil: Beyond an insider’s view. *Journal of Systems and Software*, 86(4):872 – 889.
- Valente, M. T. and Paixão, K. (2018). CSIndexbr: Exploring the Brazilian scientific production in Computer Science. *arXiv*, abs/1807.09266.
- Vasilescu, B., Serebrenik, A., Mens, T., van den Brand, M. G., and Pek, E. (2014). How healthy are Software Engineering conferences? *Sci. Comput. Program.*, 89:251 – 272.